Ai大模型技术基础

游戏：故事接龙

我会起一个故事的开头，每个人只能在后面添加一个字或者一个词（标点符号，如果是词最多四字成语），要求最后的故事完整且通顺。

```
公元2026年，企鹅在网络上殴打一群方块人，突然大叫不许动，方块人呆住，发现企鹅没有叫，好像不是受到攻击，究竟是被谁刺激到了，企鹅崩溃喊道：“是谁”
系统异常崩溃了。
```

我们每个人在续写的时候，都是在根据前面已经生成的内容（上下文），预测或者选择了最合理的下一个字或者词语。

如果我们按照这种工作流程编写出一个程序，那么这个程序就会模仿这样的过程，不断的生成文本内容。

自回归生成：大模型的接龙术

现在使用的大语言模型（Large Language Model，LLM）本身的工作原理就是这样的接龙

我们给定一个文本的前端（就是我们提出的要求），模型是在预测和选择下一个最有可能或者最适合和的字或者词，然后将新生成的字拼接到原本的文本末尾，在重复的进行这样的预测和选择，直到生成完整的回答或者故事内容。

这种逐个生成，反复调用自身这个方式，我们称之为自回归生成。

智能的假设

在计算机科学邻域中，存在一个基础假设：任何可计算的问题，理论上都可以用一个函数来表示

我们目前的大模型，可以看作是这样的一个函数：`f(前缀)-->下一个字`，通过我们不停的调用这个函数，从而将故事或者内容续写填充到任意长度。

我们如今的大模型，本是上是一个参数超级多的函数（参数量不低于亿级别的参数）的超级复杂函数

大模型这里的字的生成不是简单的随机生成，而是会根据前缀中的内容，找到字和字之间存在的潜在关系从而进行预测生成（使用例如贪心策略）

大模型的发展史

- 萌芽期：1950s-2000s
    - 1950年：图灵提出“机器能思考吗？”，并设计了图灵测试
    - 1966年：ELIZA聊天机器人诞生，是基于最简单的规则匹配来实现简单的对话，例如用户输入我头疼，ELIZA就会反问你为什么会头疼
    - 1990s-2000s：机器学习兴起，人们开始使用统计学和数学模型来进行分类，回归等常见问题的实现，但是对于自然语言处理依旧需要人工编写规则
- 深度学习崛起：2012-2017年
    - 2012年：AlexNet在ImageNet的图像识别大赛中刷新了以往机器学习的实现的记录，标志深度学习时代正式开始

    - 卷积神经网络（CNN）：擅长处理网格结构数据（图像）
    - 循环神经网络（RNN）：专用于处理序列数据（文本，语言）
    - 词向量技术：让自然语言转变为空间维度的向量，语义相近的词空间距离也接近
- Transformer革命：2017年
    - 谷歌团队发表了一篇论文《Attention is All You Need》，提出了Transformer架构，一种完全不用CNN，RNN的一种全新的机制，只用一种名为自注意力的机制，并行计算每个词和其他所有词的关系，成为了自然语言处理的基石模型结构
- 预训练时代：2018年到2022年
  源于Transformer引起了两个标志性的方向
    - GPT系列：提出了预训练+微调的实现方式，实现了全新的一套模型的训练方式，取得了很强的模型能力
    - BERT系列：对Transformer架构尝试只用其编码器的部分，发现对于理解文本，回答问题等场景下能够比传统的Transformer架构更好

  这个时间节点发现了一个情况：涌现能力，当我们将模型的参数量进行增大的时候，并且增大到某个零界点的时候发现模型就具备了一些推理，分析这样的高级的能力。
- ChatGPT和全民AI：2022年年底，ChatGPT发布，不仅能够生成流畅的文本，还能近乎人类的风格进行多轮对话
- 百花齐放的时代：2023年至今
    - 国内外开源模型涌现（`Qwen`，`DeepSeek`，`ChatGLM`，`LLaMA`）
    - 2025年1月`DeepSeek-R1`出现
    - 2025年-2026年，AI Agent概念爆火，诞生大量Agent类工具，开始承担大量的工作流程，成为生产力的一部分

Transformer

传统模型在面对一些特定的语句中，会出现对意思的理解错误

```
那只猫追着老鼠跑，因为它饿了。
```

问题：它是谁？因为我们人类在看这句话的时候，提取到了整句话的主语是猫，所以这里的它指代的是猫，此外，猫追老鼠可能和猫饿了可能有关联。

Transformer会采用注意力机制，在理解一个词的含义的时候，通过其他所有的词来辅助理解

例如，在理解这个它是谁的时候，会查看整句话

发现猫和这个它的关系有

老鼠和这个它也有关系

追和它很少

发现猫是主语，它指代主语的概率会比较大

综合上面的信息，得出模型自己对它这个词的理解

对于Transformer架构而言，分为两个部分

- 编码器：只负责对文本内容和含义的理解

- 解码器：根据理解输出文本

实际我们使用的大模型存在三种类型

- 只用编码器：只用于分类，搜索，信息提取，常见的就是现在的嵌入模型
- 只用解码器：只用于生成文本内内容，常见的就是GPT、Qwen、DeepSeek
- 两个都用：一般用于翻译，内容转换等场景

Transformer实现了之前深度学习中存在的三个痛点

1. 并行计算：可以同时对文本内的每一个词计算与其他词之间的注意力信息
2. 长程依赖：自注意力机制会让每一个词和整个所有的词之间进行关联，不对只关心到局部
3. 可扩展性：结构非常简单，只需要堆层数就可以增加模型的参数量

大模型与计算机硬件

我们想要运行大模型，我们需要三个很重要的硬件指标

- 算力：大模型的本质是数学计算，所以算力直接影响模型的生成内容的快慢
- 显存：我们的模型能不能存放在我们的存储中，如果存储不下，我们就无法运行我们的模型
- 带宽：决定我们模型中计算的数据的传输速度，直接影响我们模型的生成延迟

不同于传统的软件，我们的大模型基本是依赖GPU来进行的运算的

CPU是我们传统的处理器，可以完成任意复杂的逻辑、判断和计算，我们编写的绝大多数的程序都是以CPU为计算单元来设计的

GPU原本是用于图形图像加速处理的硬件，随着时代的发展，我们引入了一些能力（CUDA），让GPU可以处理一些非图形图像的计算任务，但是这类计算任务有一个特点（不能太复杂，但是可以是多并发）

大模型的计算。95%以上的内容本质上就是矩阵乘法，是一种需要大量并发但是每个单元计算任务简单的模式，刚好符合GPU的工作模式

大模型每输出一个字，就需要吧所有的参数遍历一遍，参数越多，对应的数量也就越多，需要的读写性能和带宽也就越大

所以现在大模型是对硬件有非常高的要求的一种技术和方向

- RTX4090：价格1.3w每张，24GB的显存
- A100：价格10w每张，80GB的显存
- H200：价格35w每张，141GB的显存

如果这样来使用模型和训练模型，必然成本过高

所以我们针对性的会有一些优化手段，用更少的硬件需求来运行模型（量化，MoE等）

大模型现在与未来

最开始的时候，我们的大模型只能聊天

现在的大模型，能够看懂图片，生成图片，生成视频，甚至可以操作我们的电脑完成各种任务，甚至大模型结合我们的机器人，真的能够代替人类完成很多的任务